

Finding similar papers using ontologies

Francesco Gaetano, Luigi Lomasto, Marco Mecchia, Andrea Soldá

Gennaio 2016

1 Introduzione al problema

Il problema di trovare lavori scientifici simili scritti in linguaggio naturale é un compito molto difficile dal punto di vista informatico: Tali documenti infatti non hanno una struttura fissa, e sono pieni di elementi non facilmente confrontabili come formule, notazioni ed immagini. Inoltre, nonostante una netta predominanza dell'inglese, i documenti sono scritti in lingue diverse. Tutte queste caratteristiche, insite in lavori di ricerca di questo tipo, rendono gli approcci basati sul confronto testuale non utilizzabili. Il nostro lavoro, basato sulle meta informazioni dei documenti e sull'utilizzo di tecnologie del Semantic Web, mira a fornire un approccio alternativo ai metodi tradizionali, nonché un'infrastruttura riutilizzabile anche in altri ambiti.

Il resto del lavoro é organizzato come segue: nella sezione 2 viene presentata l'analisi da noi condotta ed i vari step che hanno portato al risultato finale. Nella sezione 3 vengono analizzati nel dettaglio le tecnologie del Web Semantico da noi utilizzate. Nella sezione 4 vengono presentate nel dettaglio le varie componenti introdotte nella sezione 2, illustrando e commentando estratti di codice del progetto. Infine, nella sezione 5 verranno commentati i risultati ottenuti ed eventuali applicazioni ed estensioni di quanto fatto.

2 Workflow

Il lavoro é stato suddiviso in diverse fasi.

2.1 Selezione del database ed estrazione delle meta-informazioni

In questa fase preliminare del lavoro, abbiamo costruito il dataset sul quale basarci per tutto il resto del lavoro. Per prima cosa abbiamo scelto il database dal quale attingere i lavori da confrontare. La nostra scelta é ricaduta su DBLP[DBLP] in quanto punto di riferimento centrale per la sottomissione dei paper nella comunitá informatica. DBLP inoltre mette a disposizione ampi dataset di meta-informazioni sugli articoli scaricabili in

formato standard xml, con relativi url alle pagine web degli articoli. Mediante gli url letti dal file dblp.xml, per ogni articolo abbiamo estratto dalla pagina sorgente l'abstract ed eventualmente topics e keywords (se presenti). Questo lavoro ci ha permesso di ottenere un primo dataset che, oltre alle informazioni di partenza, contiene anche gli abstract con eventuali topics o keywords. Poiché topics e keywords sono state estratte dalla pagina sorgente dell'articolo, é stato deciso di assegnare, per ogni topic una relevance pari ad 1, e per ogni keyword una relevance pari a 0.99.

A partire da questa prima versione, con l'utilizzo delle API di Alchemy abbiamo, per ogni abstract, estratto le keywords con le rispettive relevance, ottenendo cosí il dataset finale, sostituendo all'abstract le keywords ottenute. Il dataset finale contiene per ogni articolo le seguenti informazioni:

- Titolo del lavoro
- Autori del lavoro
- Anno di pubblicazione
- Topics (se presenti)
- Keyword (se presenti)
- Rivista
- URL

2.2 Progettazione e popolamento dell'ontologia

In questa fase, é stata studiata la progettazione di un'ontologia adatta a gestire le informazioni estratte nella fase precedente. Il passaggio ad un'ontologia é stato necessario per almeno due motivi:

1. La possibilitá di interrogare il database di meta informazioni tramite query semantiche.
2. La possibilitá di collegare il lavoro a strumenti già esistenti per i *linked data*, in modo da rendere lo strumento integrabile.

Per l'ontologia, la nostra scelta é ricaduta su CIDOC/CRM[CIDOC]. Il modello concettuale CIDOC/CRM é un stato progettato per la gestione di contenuti relativi alla storia ed alle opere d'arte, quindi si é rivelato adatto al nostro scopo.

—————Qui cé da appronfondire sullo schema che abbiamo progettato noi a partire dalle meta informazioni Francesco————

2.3 Interrogazione dell'ontologia

Una volta popolata l'ontologia é stata necessaria la progettazioni di query adatte al contesto del progetto. Le query su cui é stata dedicata maggiore attenzione sono due:

1. A partire dal titolo di un articolo, restituire keywords e topics.
2. A partire da keywords e topic ottenuti dalla query precedente, restituire la lista degli articoli che hanno un'sottoinsieme di keywords e topics in comune.
3. A partire dal titolo di un articolo, restituire tutte le informazioni quali: Autori, anno di pubblicazione, rivista, url ...

2.4 Presentazione dei risultati

Una volta progettate ed eseguite le query, abbiamo studiato un modo per poter proporre i risultati in modo elegante, ma che allo stesso tempo ponesse enfasi sullo strato semantico che lega i documenti. Per fare ciò, abbiamo generato in maniera ricorsiva un grafo centralizzato: la radice é il documento di partenza, ed il solo nodo presente nel grafo. Il livello $i + 1$ -esimo del grafo viene generato semplicemente lanciando la query principale su tutti gli articoli del livello i -esimo. Il processo viene reiterato finché non si arriva alla profondità desiderata.

3 Strumenti utilizzati

Le tecnologie utilizzate per lo sviluppo di questo progetto sono molteplici:

- Java 8 per gran parte del backend, cioè lo scraping e la popolazione dell'ontologia. Abbiamo usato le seguenti librerie:
 - jsoup per l'utilizzo di espressioni Xpath nella fase di scraping.
 - Apache Jena per la popolazione dell'ontologia e la creazione del file .owl.
 - AlchemyAPI per l'estrazione delle keywords da ogni topic.
- Abbiamo utilizzato le seguenti tecnologie del Semantic Web:
 - Protege per creare ed estendere lo schema ontologico.
 - OWL come linguaggio per definire l'ontologia.
 - SPARQL come linguaggio di query per interrogare l'ontologia.
 - Apache Fuseki come server per gestire le query.
- PHP7 per la formulazione e la sottomissione delle query lato server.

- Javascript per la parte di frontend, utilizzando le seguenti librerie:
 - vis.js per il rendering del grafo.
 - JQuery per gestire meglio le richieste ajax agli script Php lato server.
 - Bootstrap per la gestione dell'aspetto della pagina.

3.1 Jsoup

Libreria Java che permette di lavorare con documenti HTML. Fornisce delle API molto semplici con le quali é possibile estrarre e manipolare i dati a partire dal DOM di una pagina mediante l'uso di espressioni XPath.

Esempio

```
Document doc = Jsoup.connect(URL).timeout(50*1000).get();
Elements elemsAbstract = doc.select("p.Para");
```

3.2 Protégé

Protégé é un framework open source sviluppato presso l'università di Stanford, esso dispone di un'interfaccia grafica per la definizione di schemi ontologici e della semantica alla base di essi. Tramite il tool é stato possibile importare lo schema ontologico tipico di CIDOC-CRM sulla quale successivamente si é reso necessario la definizione di classi e propriét supplementari per estendere lo schema in uno maggiormente adatto per la nostra applicazione.

3.3 Apache Jena

Apache Jena un framework open source per Java, il quale fornisce API per la lettura e scrittura di grafi RDF. In particolare, é stato utilizzato per la lettura dello schema precedentemente realizzato con Protégé e per la successiva scrittura di uno schema OWL comprendente le istanze a partire da un dataset in input.

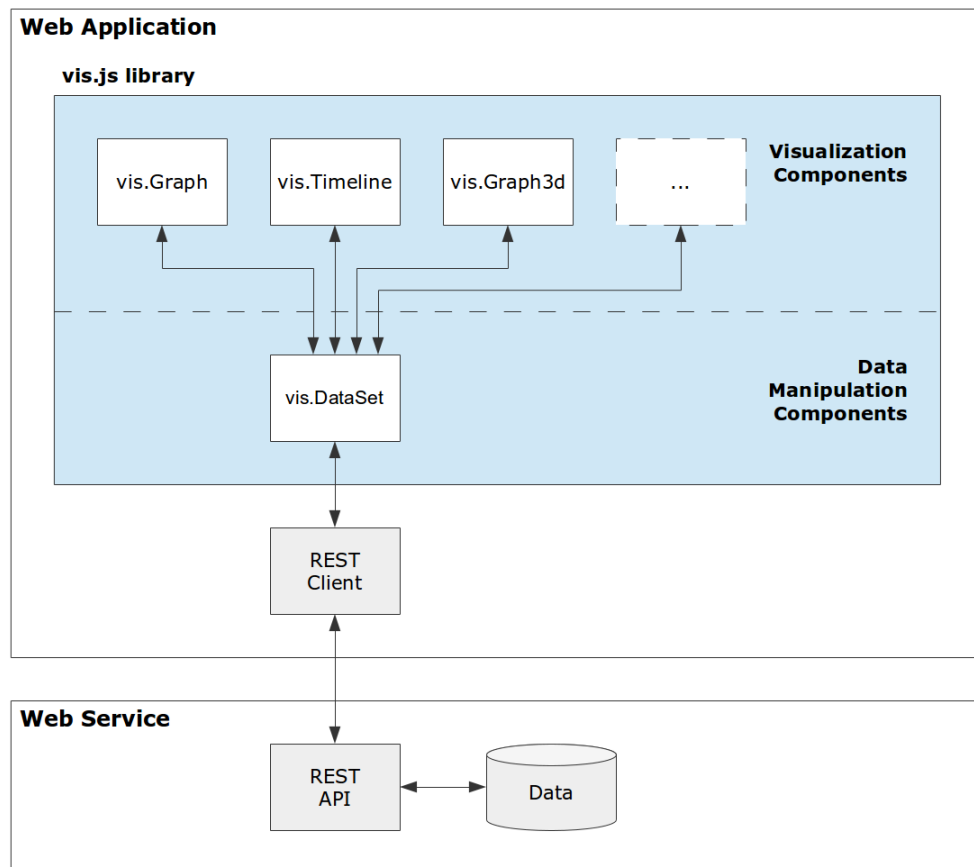
3.4 AlchemyAPI

AlchemyAPI utilizza algoritmi per l'apprendimento automatico che permettono di estrarre meta-dati semantici dal contenuto desiderato, come ad esempio informazioni su persone, luoghi, aziende, gli argomenti, i fatti, le relazioni, gli autori e le lingue. I meta-dati possono essere restituiti in formato XML, JSON e RDF.

Ad ogni parola estratta viene associato una relevance (valore numerico compreso tra 0 e 1), che indica l'incidenza della parola all'interno del testo. Nel nostro caso sono state usate parole con relevance maggiore o uguale di 0.6.

3.5 Vis.js

Vis.js é una libreria javascript che permette la visualizzazione dinamica di grafi, timeline e grafici a due o tre dimensioni. La struttura architetturale é illustrata nell'immagine seguente.



Nel nostro caso abbiamo usato tale libreria per generare un grafo contenente gli articoli con le relative relazioni semantiche. Un grafo in Vis.js é una struttura costituita da nodi ed archi. Di seguito é riportato un esempio con cinque nodi e quattro archi.

```
<!doctype html>
<html>
<head>
  <title>Network | Basic usage</title>

  <script type="text/javascript" src="../../dist/vis.
    js"></script>
</head>
```

```

<body>

<div id="mynetwork"></div>

<script type="text/javascript">
  // create an array with nodes
  var nodes = [
    {id: 1, label: 'Node 1'},
    {id: 2, label: 'Node 2'},
    {id: 3, label: 'Node 3'},
    {id: 4, label: 'Node 4'},
    {id: 5, label: 'Node 5'}
  ];

  // create an array with edges
  var edges = [
    {from: 1, to: 2},
    {from: 1, to: 3},
    {from: 2, to: 4},
    {from: 2, to: 5}
  ];

  // create a network
  var container = document.getElementById('mynetwork')
    ;
  var data= {
    nodes: nodes,
    edges: edges,
  };
  var options = {
    width: '400px',
    height: '400px'
  };
  var network = new vis.Network(container, data,
    options);
</script>

</body>
</html>

```

4 Implementazione

4.1 Costruzione del dataset

Per costruire il dataset di meta-informazioni dei documenti presenti su DBLP, é stato sviluppato un package java chiamato *scraper*, costituito dalle seguenti classi:

.java Contenente il main. Si occupa, preso in input il dataset di meta-informazioni degli articoli scaricabile da DBLP, di eliminare le informazioni superflue e di invocare le classi di scraping quando si trova l'elemento `url`.

SuperScraper.java Superclasse astratta degli scraper, utile per il polimorfismo.

FactoryScraper.java Implementazione del Factory Method per gli scraper.

IJIEMScraper.java Istanza di SuperScraper.

JDisplaScraper.java Istanza di SuperScraper.

JkdbScraper.java Istanza di SuperScraper.

StandardScraper.java Istanza di SuperScraper.

```
Count
1 public class Count {
2     public static void main(String [] args) throws
        FileNotFoundException, IOException {
3         BufferedReader reader = new BufferedReader(new FileReader(
            args[1]));
4         FileWriter w = new FileWriter(args[2]);
5
6         parsing(reader, line, w);
7         w.close();
8         reader.close();
9     }
10
11     private static void parsing(BufferedReader reader, FileWriter
        w) throws IOException {
12         int nArticoli=0;
13         SuperScraper scraper;
14         FactoryScraper f = new FactoryScraper();
15
16         do{
17             line = reader.readLine();
18             if(line.contains("<article")){
19                 ++nArticoli;
20             }
21             else
```

```

22         if (line.contains("<ee>")){
23             scraper = f.createScraper(line);
24             scraper.scrape(w, line);
25         }
26         if (GENERATE)
27             w.write(line+"\n");
28     } while (line!=null && nArticoli <=5000);
29     w.flush();
30     System.out.println(nArticoli);
31 }
32 }

```

Listing 1: Count.java

Il main prende due argomenti da linea di comando: il primo corrisponde al percorso del file xml di informazioni di DBLP, ed il secondo al nome del file dove ricopiare il dataset aggiornato. Il cuore della classe é costituito dal metodo statico parsing: Tale metodo legge il file XML riga per riga, fino a trovare la riga contenente l'URL dell'articolo; una volta trovato, la factory crea uno scraper apposito in base al contenuto della linea. Lo scraper si occupa di effettuare la connessione all'url, di estrarre l'abstract dalla pagina web e di aggiornare il file di output. Grazie al Factory Method ed al polimorfismo, aggiungere nuovi scraper e' semplicissimo, e non richiede l'intervento diretto sul main. Il numero di articoli é stato impostato a 5000 poiché tale numero si é rivelato sufficiente per costruire il nostro dataset.

StandardScraper La classe StandardScraper é un'istanza della super-classe SuperScraper, e si occupa di scrivere in output le informazioni estratte da un articolo in un file xml.

```

1 public class StandardScraper extends SuperScraper {
2
3     @Override
4     public void scrape(FileWriter w, String line) throws
5         IOException {
6         if (GENERATE)
7             w.write("<abstract>\n");
8
9         String URL[]=line.split("<ee>");
10        String URL2[]=URL[1].split("</ee>");
11        try{
12            Document page=returnPage(URL2[0]);
13            Elements elemsAbstract = page.select("p.Para");
14            for (Element elem: elemsAbstract){
15                if (DEBUG)
16                    System.out.println(elem.text().toString());
17                if (GENERATE)
18                    w.write(elem.text().toString());
19            }
20            if (GENERATE)
21                w.write("\n</abstract>\n");

```



```

21 Elements elemsKeyWord = page.select("ul.abstract-about-
    subject > li > a");
22 for(Element elem: elemsKeyWord){
23     if(DEBUG)
24         System.out.println(elem.text().toString());
25     if(GENERATE)
26         w.write("<topic>");
27     w.write(elem.text().toString());
28     w.write("</topic>\n");
29 }
30
31 }
32 catch(ConnectException e){ w.write("\n</abstract>\n");
    failureConnect++;if(DEBUGException){System.out.print("
    Connessione rifiutata "+URL2[0]+" ");System.out.println(
    failureConnect);}}
33 catch(HttpStatusException e){w.write("\n</abstract>\n");
    failureConnect++;if(DEBUGException){System.out.print("
    Status=404 "+URL2[0]+" ");System.out.println(
    failureConnect);}}
34 catch(SocketTimeoutException e){w.write("\n</abstract>\n");
    failureConnect++;if(DEBUGException){System.out.print("
    Socket timeout "+URL2[0]+" ");System.out.println(
    failureConnect);}}
35 catch(UnknownHostException e){w.write("\n</abstract>\n");
    failureConnect++;if(DEBUGException){System.out.print("dx.
    doi.org "+URL2[0]+" ");System.out.println(failureConnect
    );}}
36 catch(UnsupportedMimeTypeException e){w.write("\n</abstract
    >\n"); failureConnect++;if(DEBUGException){System.out.
    print("jsoup "+URL2[0]+" ");System.out.println(
    failureConnect);}}
37
38 }
39
40 }

```

Listing 2: StandardScraper.java

Questo tipo di output e' lo stesso per tutte le istanze degli scraper. Quello che differenzia ogni scraper e' la struttura della pagina che vanno ad esaminare, per cui sono richiesti controlli ed espressioni Xpath diverse per estrarre le informazioni giuste. Se il documento contiene delle keyword, esse vengono aggiunte in un apposito tag dopo i topic, prima della chiusura del tag relativo all'articolo.

```

<article mdate="2011-01-11" key="journals/acta/Saxena96">
<author>Sanjeev Saxena</author>
<title>Parallel Integer Sorting and Simulation Amongst CRCW
    Models.</title>
<pages>607-619</pages>
<year>1996</year>

```

```

<volume>33</volume>
<journal>Acta Inf.</journal>
<number>7</number>
<url>db/journals/acta/acta33.html#Saxena96</url>
<abstract>In this paper a general technique for reducing
    processors in simulation without any increase in time is
    described.</abstract>
<topic>Logics and Meanings of Programs</topic>
<topic>Computer Systems Organization and Communication
    Networks</topic>
<topic>Software Engineering/Programming and Operating Systems<
    /topic>
<topic>Data Structures, Cryptology and Information Theory</
    topic>
<topic>Theory of Computation</topic>
<topic>Information Systems and Communication Service</topic>
<ee>http://dx.doi.org/10.1007/BF03036466</ee>
</article>

```

Listing 3: Esempio di xml prodotto dallo StandardScraper

FactoryScraper

```

1 public class FactoryScraper {
2
3     private SuperScraper jdispla;
4     private SuperScraper jkdb;
5     private SuperScraper ijiem;
6     private SuperScraper standard;
7
8     public FactoryScraper(){
9         jdispla = new JDisplaScraper();
10        jkdb = new JkdbScraper();
11        ijiem = new IJIEMScraper();
12        standard = new StandardScraper();
13    }
14
15    public SuperScraper createScraper(String line){
16
17        if(line.contains("<ee>")){
18            if(line.contains("j.displa.") || line.contains("j.compind")
19                ){
20                return jdispla;
21            }
22            else{
23                if(line.contains("jkdb")){
24                    return jkdb;
25                } else if(line.contains("IJIEM.")){
26                    return ijiem;
27                }
28            }
29        }
30    }
31 }

```

```

27         else{
28             return standard;
29         }
30     }
31 }
32 return null;
33 }
34 }

```

Listing 4: FactoryScraper.java

La FactoryScraper alla sua creazione crea un tipo di oggetto per ogni specializzazione della classe SuperScraper; in questo modo, quando c'è bisogno di fare il parsing di un nuovo documento non si crea ogni volta un nuovo oggetto, ma si utilizza sempre lo stesso. Così facendo, gli oggetti vengono riutilizzati e vengono risparmiati memoria e processore, in quanto la Garbage Collector di Java non deve essere invocata di continuo. Il metodo createScraper si deve solamente occupare di verificare le condizioni per cui deve essere creato un tipo di Scraper piuttosto che un altro.

4.2 Estrazione delle Keyword

Per l'estrazione delle keyword a partire dall'abstract è stato fatto uso delle API messe a disposizione dal software Alchemy[alchemy], scaricabili gratuitamente. Tale software è composto da molti strumenti utili per l'analisi linguistica, tra cui l'estrazione di parole chiave da un testo con rilevanze normalizzate nell'intervallo $[0, 1]$. Gli unici limiti riscontrati sono stati il fatto di doversi registrare per ottenere una chiave per utilizzare le API ed il relativo limite di chiamate giornaliere.

Il pacchetto *keyword* sviluppato nel progetto è composto da due classi:

KeywordExtractor è una classe di wrapper per la chiamata al metodo di AlchemyAPI che dato un testo restituisce le keyword rankate.

ScraperForKeyword è la classe contenente il metodo main del pacchetto.

Si occupa di aggiungere al dataset generato con il pacchetto scraper le keyword estratte con la classe KeywordExtractor.

ScraperForKeyword

```

1 captioncaption
2 public class scraperForKeyword {
3     private static String getStringFromDocument(Document doc)
4         throws IOException {
5         try {
6             DOMSource domSource = new DOMSource(doc);
7             StringWriter writer = new StringWriter();
8             StreamResult result = new StreamResult(writer);
9             String toReturn="";
10            TransformerFactory tf = TransformerFactory.newInstance();

```

```

10 Transformer transformer = tf.newTransformer();
11 transformer.transform(domSource, result);
12
13 String [] split=writer.toString().split("<keyword>");
14
15 for(int i=1;i<split.length;i++){
16     String [] relevance1=split[i].split("<relevance>");
17     String [] relevance2=relevance1[1].split("</relevance>");
18     String [] text1=split[i].split("<text>");
19     String [] text2=text1[1].split("</text>");
20
21     double relevance = Double.parseDouble(relevance2[0]);
22     if(relevance*10 >= 6){
23         toReturn+="<keyword>\n";
24         toReturn+="<relevance>"+relevance+"</relevance>\n";
25         toReturn+="<text>"+text2[0]+"</text>\n";
26         toReturn+="</keyword>\n";
27     }
28 }
29
30 return toReturn;
31 } catch (TransformerException ex) {
32     ex.printStackTrace();
33     return null;
34 }
35 }
36
37 public static void main(String [] args) throws IOException,
38     XPathExpressionException, SAXException,
39     ParserConfigurationException{
40     int nArticoli = Integer.parseInt(args[0]);
41     int numeroRigheLette;
42     int articoliGialetti=nArticoli;
43     int articoliDaLeggere=Integer.parseInt(args[1]);
44     boolean abstractB=false;
45     BufferedReader reader = new BufferedReader(new FileReader(
46         args[2]));
47     String line = reader.readLine();
48     String abstract_Text="";
49     FileWriter w=new FileWriter(args[3]);
50     String api_path = args[4];
51     int counter=0;
52
53     while(counter<=nArticoli){
54         line = reader.readLine();
55         if(line.contains("<article>"))
56             ++counter;
57     }
58     while(line!=null && nArticoli<articoliDaLeggere+
59         articoliGialetti) {
60         if(line.contains("<article>")){
61             ++nArticoli;
62             if(nArticoli<articoliDaLeggere+articoliGialetti){
63                 w.write(line+"\n");}
64         }
65     }

```

```

60     abstractB=false;
61 }
62 else
63     if(line.contains("<abstract>")){
64         abstract_Text+=line;
65         abstractB=true;
66     }
67     else if(abstractB && line.contains("</abstract>")){
68         abstractB=false;
69         abstract_Text=abstract_Text.replace("<abstract>", "");
70         abstract_Text=abstract_Text.replace("</abstract>", "");
71         if(!abstract_Text.equals("")){
72             try{
73                 Document s=KeywordExtractor.extractKeyword(
74                     abstract_Text, api_path);
75                 String keywordDocument = getStringFromDocument(s);
76                 w.write(keywordDocument);
77             }
78             catch(IOException e){
79                 System.out.println("Error making API call:
80                                     unsupported-text-language.");
81             }
82             abstract_Text="";
83         }
84         else if(abstractB){
85             abstract_Text+=line;
86         }
87         else
88             w.write(line+"\n");
89         line = reader.readLine();
90     }
91 w.close();
92 System.out.println("#Articoli letti: "+ --nArticoli);
93 }
94 }

```

./src/keywords/scraperForKeyword.java

Il main prende in input 5 argomenti: il numero di articoli già letti, il numero di articoli da leggere, il percorso del file di input¹, il percorso del file di output ed il percorso della chiave per utilizzare le API di Alchemy. Il numero di articoli già letti e quelli da leggere sono parametri necessari introdotti dal limite di chiamate di AlchemyAPI; in questo modo il lavoro é stato diviso tra i componenti del team in maniera facilmente ricostruibile.

Dopo aver saltato gli articoli già letti, il parser per ogni articolo trova l'abstract ed esegue una chiamata al metodo statico ExtractKeyword della classe KeywordExtractor. Grazie al metodo di utilità getStringFromDocument, il documento xml contenente le keyword dell'abstract viene serializ-

¹Nel file ci sono già gli abstract, estratti con il pacchetto scraper.

zato. La stringa corrispondente al documento serializzato a questo punto viene concatenata alle informazioni del documento e viene quindi scritta in output.

KeywordExtractor La classe é composta dal solo metodo statico `ExtractKeyword`. Tale metodo prende in input il testo da cui estrarre le parole chiave ed il percorso del file contenente la chiave fornita dal sito web di Alchemy. Il metodo restituisce un documento xml sotto forma di oggetto `Document`; in questo modo é facilmente serializzabile, oltre che navigabile con gli strumenti del DOM.

```
1 public class KeywordExtractor {
2
3     public static Document extractKeyword(String text, String
        api_path) throws IOException, XPathExpressionException,
        SAXException, ParserConfigurationException {
4         AlchemyAPI alchemyObj = AlchemyAPI.GetInstanceFromFile(
            api_path);
5         return alchemyObj.TextGetRankedKeywords(text);
6     }
7
8 }
```

Listing 5: KeywordExtractor.java

```
<keywords>
<keyword>
<relevance>0.986122</relevance>
<text>tree schemas</text>
</keyword>
<keyword>
<relevance>0.868575</relevance>
<text>NP-complete problems</text>
</keyword>
<keyword>
<relevance>0.830641</relevance>
<text>certain NP-complete problems</text>
</keyword>
</keywords>
```

Listing 6: Esempio di documento restituito dalla classe `KeywordExtractor`

4.3 Lo schema ontologico

Una volta realizzato il dataset con le relative informazioni, il passo successivo stato quello di definire la semantica sottostante. L'idea stata quella di partire da uno schema esistente che fosse flessibile per avere l'opportunit  di estenderlo nel caso fosse stata necessaria l'aggiunta di ulteriori entit .

4.3.1 Conceptual Reference Model (CRM);

Il modello utilizzato è il CIDOC-CRM, usato da musei ed altre istituzioni culturali per la descrizione di relazioni tra entità per valorizzare lo scambio di informazioni tra fonti eterogenee.

Per definizione, un'ontologia è CRM compatibile se rispetta lo schema di base proposto dagli autori.

Lo schema di base attualmente comprende 93 classi e 165 proprietà delle quali solo un sottoinsieme sono risultate funzionali al nostro obiettivo:

- Entità
 1. **E1_Production:** In CRM un oggetto reale opportuno vederlo come il risultato di un'attività (in questo l'attività descritta come produzione). Nel nostro caso un qualsiasi articolo può essere visto come il prodotto risultante

Per rappresentare in modo corretto le informazioni estratte da DBLP è stato necessario aggiungere, allo schema di base del CRM, altre classi e proprietà.

E1	CRM Entity
E2	- TemporalEntity
E4	- - Period
E5	- - - Event
E7	- - - - Activity
E11	- - - - - Modification
E12	- - - - - - Production
E13	- - - - - Attribute Assignment
E65	- - - - - Creation
E63	- - - - - Beginning of Existence
<i>E12</i>	- - - - - <i>Production</i>
E65	- - - - - Creation
E64	- - - - - End of Existence
E77	- PersistentItem
E70	- - Thing
E72	- - - Legal Object
E18	- - - - Physical Thing
E24	- - - - - Physical Man-Made Thing
E90	- - - - - Symbolic Object
E71	- - - - Man-Made Thing
<i>E24</i>	- - - - - <i>Physical Man-Made Thing</i>
E28	- - - - - Conceptual Object
E89	- - - - - Propositional Object
E30	- - - - - - Right
E73	- - - - - - Information Object
<i>E90</i>	- - - - - <i>Symbolic Object</i>
E41	- - - - - - Appellation
<i>E73</i>	- - - - - - <i>Information Object</i>
E55	- - - - - Type
E39	- - Actor
E74	- - - Group
E52	- Time-Span
E53	- Place
E54	- Dimension
E59	Primitive Value
E61	- Time Primitive 16
E62	- String

4.3.2 Estensioni al CRM

Essendo un modello principalmente progettato per le istituzioni culturali, stato necessario effettuare delle aggiunte allo schema di partenza. Di seguito verranno elencate le entit e le propriet con le opportune motivazioni:

4.4 Popolamento dell'ontologia

4.5 Query SPARQL

Per poter effettuare al meglio le query sull'ontologia abbiamo deciso di implementare la classe *query-sparql* (file *query.php*). Tale classe costituita da funzioni che, quando chiamate, restituiscono la query ad esse associate.

La lista degli articoli che contengono un sottoinsieme di keywords e topics dei medesimi dell'articolo di partenza, viene resituata in formato JSON dal file *ricerca.php* all'interno del quale vengono fatte le chiamate a funzione della classe *query-sparql*. Il JSON restituito é un array contenente la lista di keywords e topics dell'articolo di partenza e da un array contenete oggetti di tipo *article* dove per ognuno riportata la lista di keyword e topic che corrispondono, il titolo e l'id che identifica univocamente il nodo del grafo successivamente associato. Di seguito sono riportate alcune delle query Sparql usate per interrogare l'ontologia. Per ulteriori chiarimenti consultare i file *query.php* e *ricerca.php*.

- **Dal titolo di un articolo estrarre topic.**

```
prefix crm: <http://www.cidoc-crm.org/cidoc-crm/>
prefix owl: <http://www.w3.org/2002/07/owl#>
prefix sd: <http://www.semanticweb.org/francesco/
          ontologies/2016/docs#>
```

```
SELECT  ?title_value ?topic_value
```

```
WHERE{
  ?prod crm:P108_has-produced ?doc.
  ?doc crm:P102_has-title ?title.
  ?title sd:Title_value "Representation of Graphs" .
  ?title sd:Title_value ?title_value.
  ?doc crm:P56_bears-feature ?topic.
  ?topic sd:Topic_value ?topic_value.
}
```

- **Dal titolo di un articolo estrarre keywords e relevance.**

```

prefix crm: <http://www.cidoc-crm.org/cidoc-crm/>
prefix owl: <http://www.w3.org/2002/07/owl#>
prefix sd: <http://www.semanticweb.org/francesco/
          ontologies/2016/docs#>

```

```

SELECT  ?title_value ?t ?r

```

```

WHERE{
  ?prod crm:P108_has-produced ?doc.
  ?doc crm:P102_has-title ?title.
  ?title sd:Title_value "Representation of Graphs
    ".
  ?title sd:Title_value ?title_value.
  ?doc crm:P149_is_identified_by ?key.
  ?key sd:Text ?t.
  ?key sd:Relevance ?r
}

```

- **Dalle keywords dell’articolo di partenza estrae gli articoli che hanno un sottoinsieme di keyword in comune, escludendo l’articolo di partenza.**

```

prefix crm: <http://www.cidoc-crm.org/cidoc-crm/>
prefix owl: <http://www.w3.org/2002/07/owl#>
prefix sd: <http://www.semanticweb.org/francesco/
          ontologies/2016/docs#>
prefix xsd: <http://www.w3.org/2001/XMLSchema#>

```

```

SELECT  ?title_value (SUM(xsd:double(?r)) as ?
          totalR)

```

```

WHERE
{
  {?prod crm:P108_has-produced ?doc.
  ?doc crm:P102_has-title ?title.
  ?title sd:Title_value ?title_value.
  ?doc crm:P149_is_identified_by ?key.
  ?key sd:Relevance ?r.
  ?key sd:Text ?t.
  FILTER(?t="following sense")} UNION
  {?prod crm:P108_has-produced ?doc.
  ?doc crm:P102_has-title ?title.
  ?title sd:Title_value ?title_value.

```

```

?doc crm:P149_is_identified_by ?key.
?key sd:Relevance ?r.
?key sd:Text ?t.
    FILTER(?t="transition systems"}) UNION
{?prod crm:P108_has_produced ?doc.
?doc crm:P102_has_title ?title.
?title sd:Title_value ?title_value.
?doc crm:P149_is_identified_by ?key.
?key sd:Relevance ?r.
?key sd:Text ?t.
    FILTER(?t="label-disjoint cycles"}) UNION
{?prod crm:P108_has_produced ?doc.
?doc crm:P102_has_title ?title.
?title sd:Title_value ?title_value.
?doc crm:P149_is_identified_by ?key.
?key sd:Relevance ?r.
?key sd:Text ?t.
    FILTER(?t="finite labelled transition"}) UNION
{?prod crm:P108_has_produced ?doc.
?doc crm:P102_has_title ?title.
?title sd:Title_value ?title_value.
?doc crm:P149_is_identified_by ?key.
?key sd:Relevance ?r.
?key sd:Text ?t.
    FILTER(?t="finite set"})}

FILTER(?title_value!="A decomposition theorem
    for finite
    persistent transition systems").
}

group by ?title_value
ORDER BY DESC(?totalR)

```

- **Dai topics dell’articolo di partenza estrae gli articoli che hanno un sottoinsieme di topic in comune, escludendo l’articolo di partenza.**

```

prefix crm: <http://www.cidoc-crm.org/cidoc-crm/>
prefix owl: <http://www.w3.org/2002/07/owl#>
prefix sd: <http://www.semanticweb.org/francesco/
    ontologies/2016/docs#>

```

```

SELECT    ?title_value (COUNT(DISTINCT ?topic_value
                                ) AS ?count)

WHERE{
  ?prod crm:P108_has_produced ?doc.
  ?doc  crm:P56_bears_feature ?topic.

  {?topic sd:Topic_value "Software Engineering/
    Programming and Operating Systems".} UNION
  {?topic sd:Topic_value "Computer Systems
    Organization and Communication Networks".}
  UNION
  {?topic sd:Topic_value "Computational
    Mathematics and Numerical Analysis".} UNION
  {?topic sd:Topic_value "Information Systems and
    Communication Service".} UNION
  {?topic sd:Topic_value "Theory of Computation".}
  UNION
  {?topic sd:Topic_value "Data Structures ,
    Cryptology and Information Theory".}.
  ?topic sd:Topic_value $topic_value.

  ?doc crm:P102_has_title ?title.
  ?title sd:Title_value ?title_value.

  FILTER (?title_value != "Representation of
    Graphs").
}
GROUP BY ?title_value
ORDER BY ?title_value

```

Terminata la generazione del grafo, é stato necessario effettuare ulteriori query per estrarre le informazioni di ogni articolo ottenuto. Il file *datiArticolo.php* restituisce, come visto prima per il file *ricerca.php*, un file JSON contenente le informazioni richieste.

Di seguito le query usate:

- **Restituisce gli autori di un articolo**

```

prefix crm: <http://www.cidoc-crm.org/cidoc-crm/>
prefix owl: <http://www.w3.org/2002/07/owl#>
prefix sd: <http://www.semanticweb.org/francesco/
  ontologies/2016/docs#>
prefix xsd: <http://www.w3.org/2001/XMLSchema#>

```

```

SELECT  ?author_name

WHERE{
  ?prod crm:P108_has-produced ?doc.
  ?doc crm:P102_has-title ?title.
  ?title sd:Title_value "Representation of Graphs
    ".
  ?prod crm:P14_carried-out-by ?author.
  ?author sd:name ?author_name
}

```

- **Restituisce anno di pubblicazione e rivista**

```

prefix crm: <http://www.cidoc-crm.org/cidoc-crm/>
prefix owl: <http://www.w3.org/2002/07/owl#>
prefix sd: <http://www.semanticweb.org/francesco/
  ontologies/2016/docs#>
prefix xsd: <http://www.w3.org/2001/XMLSchema#>

```

```

SELECT  ?journal ?anno

WHERE{
  ?prod crm:P108_has-produced ?doc.
  ?doc crm:P102_has-title ?title.
  ?title sd:Title_value "On the Power of Chain
    Rules in Context Free Grammars".
  ?doc sd:published-by ?journal.
  ?prod crm:P4_has-time-span ?date.
  ?date sd:Anno ?anno

}

```

- **Restituisce l'url di un articolo**

```

prefix crm: <http://www.cidoc-crm.org/cidoc-crm/>
prefix owl: <http://www.w3.org/2002/07/owl#>
prefix sd: <http://www.semanticweb.org/francesco/
  ontologies/2016/docs#>
prefix xsd: <http://www.w3.org/2001/XMLSchema#>

```

```

SELECT ?url_value
  WHERE{
    ?prod crm:P108_has-produced ?doc.

```

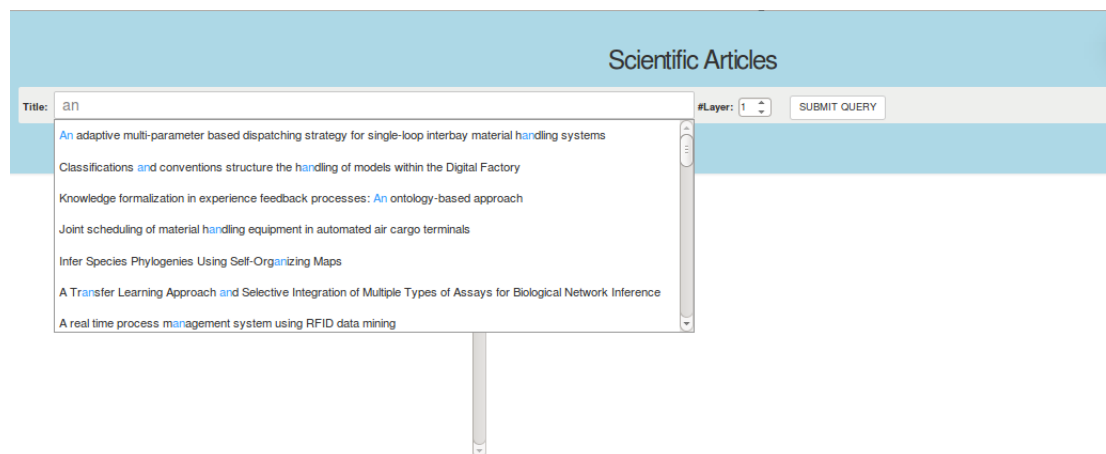
```

?doc crm:P102_has_title ?title .
?title sd:Title_value "Representation of Graphs
" .
?doc crm:P67_refers_to ?url .
?url sd:Url_value ?url_value
}

```

4.6 Front-end

Il lavoro viene presentato come una pagina web interattiva mediante la quale possibile, partendo dall'articolo inserito, visualizzare il grafo generato dalle relazioni semantiche che l'articolo cercato ha con gli altri articoli dell'ontologia. Il layout é molto semplice e sfrutta lo stile di base offerto da Bootstrap.



La Search Bar é stata implementata in javascript (*autocomplete.js*). I titoli degli articoli sono contenuti in un array che viene, ad ogni immissione, richiamato per mostrare i titoli che soddisfano la ricerca. Sottomessa la query, viene invocata la funzione *generate-graph*.

```

1  nodesMap = {};
2  edgeId = 0;
3  topicsCheckbox=new Array();
4  keywordsCheckbox=new Array();
5  articlesCheckbox=new Array();
6
7
8
9  newNodesNextLevel.push(title);
10
11  for(var i = 0; i < layer;i++){
12
13      newNodes = newNodesNextLevel.slice();
14      newNodesNextLevel = [];
15
16      while(newNodes.length > 0){
17          //for(var j = 0; j < len; j++){
18          //var d = newNodes[j];
19
20          var d = newNodes[0];
21          newNodes.splice(0,1);
22
23          $.ajax(
24          {
25              method: 'post',
26              url: 'ricerca.php',
27              data:
28              {
29                  'title': d
30              },
31              success: function(data){
32                  generate_graph(data, d, i);
33                  extractKeywordsAndTopics(data);
34              },
35              async: false
36          });
37      }
38  }
39
40  drawGraph(nodes, edges);
41
42  });
43
44
45
46  function generate_graph(data, title, layer) {
47
48  try {
49      var parsedData = JSON.parse(data);
50      }
51  catch(err) {
52      console.log(data);
53      }

```

```

54
55 //adding root if nodes is empty
56 if(nodes.length == 0){
57     nodes.push(JSON.parse( '{"id":"' + title +'", "label": "s",
58                             "title":"' Sorgente'", "color": "' + color[0] + '"}' ));
59 }
60 for(var key in parsedData.articles){
61     var existFlag = false;
62     var existEdgeFlag = false;
63     var article = parsedData.articles[key];
64     var actualId = article.id;
65     var actualTitle = article.title;
66     var relation="<b>Topics:</b><BR>";
67     var actualEdge = {};
68     var edgeValue = 0;
69     var sumOfRelevance = 0;
70     actualEdge["sourceTitle"] = title;
71     actualEdge["title"] = actualTitle;
72     actualEdge["keyword"] = article.keyword;
73     actualEdge["topic"] = article.topic;
74
75     for(var key2 in article.topic ){

```

Listing 7: indexVisjs.html

Scientific Articles

Title: #Layer:

Item selected: An adaptive multi-parameter based dispatching strategy for single-loop interbay material handling systems

Node information

TITLE: An adaptive multi-parameter based dispatching strategy for single-loop interbay material handling systems
JOURNAL: Computers in Industry
AUTHORS: P. Y. Mok, J. Zhang, L. H. Wu
YEAR: 2011
KEYWORDS: better performance, Takagi-Sugeno fuzzy logic, buffer status parameters, mm semiconductor wafer, Interbay material handling system, Multi-parameter, interbay material, Semiconductor wafer fabrication, Adaptive, Vehicle dispatching, multi-attribute dispatching methodologies, interbay systems, due-date satisfaction rate, mass transportation demands
TOPICS:

Keywords

<input type="checkbox"/> better performance	<input type="checkbox"/> Multi-parameter	<input type="checkbox"/> multi-attribute dispatching methodologies	<input type="checkbox"/> Composite dispatching rules
<input type="checkbox"/> Takagi-Sugeno fuzzy logic	<input type="checkbox"/> interbay material	<input type="checkbox"/> interbay systems	<input type="checkbox"/> Multiple-objective scheduling
<input type="checkbox"/> buffer status parameters	<input type="checkbox"/> Semiconductor wafer fabrication	<input type="checkbox"/> due-date satisfaction rate	<input type="checkbox"/> well-known methods
<input type="checkbox"/> mm semiconductor wafer	<input type="checkbox"/> Adaptive	<input type="checkbox"/> mass transportation demands	<input type="checkbox"/> global information
<input type="checkbox"/> Interbay material handling system	<input type="checkbox"/> Vehicle dispatching	<input type="checkbox"/> Genetic programming	<input type="checkbox"/> adaptive-hierarchical filter
<input type="checkbox"/> Noise removal	<input type="checkbox"/> global image structure	<input type="checkbox"/> LCD touchscreens	<input type="checkbox"/> evaluation items

5 Conclusioni

Un altro utilizzo interessante, anche se non pienamente pertinente con gli obiettivi del lavoro, é la possibilità di prevedere query che prendano in input dei topic e restituiscano tutti gli articoli che hanno quel topic e le relative parole chiave. In questo modo, cambiando il contesto (e.g. l'ontologia viene popolata con un set diverso di articoli, magari provenienti da una serie di conferenze), si può mostrare come lo stesso argomento viene trattato in maniera diversa a seconda del contesto. Se ad esempio il topic é *Bioinformatica*, in un contesto di proceedings di conferenze informatiche le parole chiave potrebbero essere *Algoritmi*, *Strutture Dati*, *Complessità Computazionale*, etc. Mentre lo stesso topic in un contesto di proceedings di conferenze biologiche potrebbe avere come parole chiave *Ribosomi*, *Proteine*, etc.